

Inteligência Artificial Generativa Aplicada na Análise da Produção Científica

Aula 02/12

Prof. Dr. Edson Melo de Souza

Programa de Pós-Graduação em Informática e Gestão do Conhecimento (PPGI)
Programa de Pós-Graduação em Gestão de Projetos (PPGP)
Universidade Nove de Julho

8 de abril de 2026

Gestão de Dados Científicos e as Leis de Bradford, Lotka e Zipf

- ▶ Compreender a importância da Gestão de Dados Científicos (GDC) na pesquisa moderna.
- ▶ Compreender os fundamentos das Leis de Bradford, Lotka e Zipf.
- ▶ Interpretar graficamente e matematicamente a distribuição da produção científica.
- ▶ Aplicar essas leis para solucionar problemas de gestão de coleções e organização de dados científicos (metadados).

O Que é Gestão de Dados Científicos?

A Gestão de Dados Científicos (GDC) é o processo ativo de coletar, organizar, armazenar, preservar e compartilhar dados gerados durante uma pesquisa.

- ▶ Garante a qualidade e integridade dos dados.
- ▶ Maximiza o impacto da pesquisa.
- ▶ Promove a transparência e reprodutibilidade.
- ▶ Atende a requisitos de agências de fomento.

O ciclo de vida dos dados descreve as etapas fundamentais da gestão:

1. **Planejamento e Coleta:** Definição do Plano de Gestão (PGD) e métodos de coleta.
2. **Processamento e Análise:** Limpeza, organização e análise dos dados brutos.
3. **Armazenamento:** Uso de repositórios e garantia de segurança a longo prazo.
4. **Compartilhamento e Reúso:** Publicação dos dados, metadados e fomento a novas pesquisas.

O Plano de Gestão de Dados (PGD)

O PGD é um documento formal que descreve como os dados serão gerenciados ao longo do ciclo de vida da pesquisa. Elementos chave incluem:

- ▶ **Tipos de dados:** a serem gerados (ex: tabulares, imagens, código).
- ▶ **Padrões de metadados:** para descrever os dados.
- ▶ **Políticas de armazenamento:** e backup durante a pesquisa.
- ▶ **Questões éticas e de privacidade:** (ex: dados sensíveis, LGPD).
- ▶ **Estratégia de compartilhamento:** e preservação a longo prazo.

Princípios Fundamentais: FAIR

Os princípios FAIR guiam o compartilhamento e a reutilização de dados para que sejam:

- ▶ **Findable (Localizáveis):** Dados e metadados com identificadores únicos (ex: DOI) e indexados em mecanismos de busca.
- ▶ **Accessible (Acessíveis):** Dados recuperáveis por seus metadados, com protocolos abertos e autenticação clara.
- ▶ **Interoperable (Interoperáveis):** Usam vocabulários controlados e formatos padronizados para integração com outros dados.
- ▶ **Reusable (Reutilizáveis):** Metadados ricos, licença de uso clara e conformidade com padrões da comunidade.

"A Ciência Aberta visa tornar a pesquisa acessível a todos. A GDC fornece a infraestrutura para que isso aconteça de forma eficaz e ética."

Benefícios da GDC na Ciência Aberta:


- ▶ **Impacto Ampliado:** Dados bem gerenciados e abertos são mais citados e reutilizados (potencial de +50% de aumento), ampliando o impacto do pesquisador e da instituição.
- ▶ **Otimização de Financiamento:** Evita a coleta desnecessária de dados.

O Caos da Informação

A ciência produz dados em volume massivo. Sem padrões matemáticos, a gestão seria baseada em tentativas e erros, levando ao caos informacional.



Leis de Lotka, Bradford e Zipf



- ▶ **Lei de Lotka (1926):** Distribuição da produtividade dos autores. Poucos autores produzem a maioria dos artigos ([ALVARADO, 2002](#)).
- ▶ **Lei de Bradford (1934):** Distribuição da literatura científica em periódicos. Poucos periódicos concentram a maior parte dos artigos relevantes ([PINHEIRO, 1983](#)).
- ▶ **Lei de Zipf (1949):** Distribuição da frequência das palavras. Poucas palavras são usadas com muita frequência, enquanto muitas palavras são usadas raramente. ([BORTOLOSSI et al., 2011](#); [PINHEIRO](#); [ALMEIDA, 2020](#))


Lei de Lotka

Produtividade dos Autores

Figura 1. Relação inversa entre o número de autores e sua produtividade, onde poucos autores publicam muito e muitos autores publicam pouco, seguindo uma distribuição do tipo potência.

A elite científica vs. a massa. O número de autores que publicam n trabalhos é aproximadamente $1/n^2$ daqueles que publicam apenas um (ALVARADO, 2002).

Exemplo: Para cada 100 autores com 1 artigo, apenas cerca de 25 terão 2 artigos ($100/2^2$), e apenas cerca de 11 terão 3 artigos ($100/3^2$)




Se você tem revistas sobre um tema, um pequeno grupo de revistas (o núcleo) contém a maior parte dos artigos relevantes (NARANAN, 1970; BROOKES, 1985).

É possível dividi-los em **zonas** contendo aproximadamente o mesmo número de artigos, mas com quantidades crescentes de periódicos tendendo a proporções próximas a $(k, kn, kn^2, kn^3, \dots)$.

- ▶ A **primeira (núcleo)** contém poucos periódicos altamente produtivos.
- ▶ A **segunda** contém mais periódicos que, juntos, publicam número semelhante de artigos.
- ▶ A **terceira** contém ainda mais periódicos, mas juntos publicam o mesmo número de artigos que as zonas anteriores.
- ▶ E assim sucessivamente.

Visualizando a Lei de Bradford

Figura 2. Distribuição da literatura em zonas de produtividade, onde poucos periódicos concentram muitos artigos e zonas sucessivas crescem na proporção $(k, kn, kn^2, kn^3, \dots)$.




Lei de Zipf

Frequência de Palavras

Em um texto, a frequência de uma palavra é inversamente proporcional ao seu ranking. A palavra mais comum aparece o dobro da segunda, o triplo da terceira, etc. (BORTOLOSSI *et al.*, 2011; PINHEIRO; ALMEIDA, 2020)

Equação: $f(r) = \frac{k}{r^\alpha}$, onde $f(r)$ é a frequência da palavra na posição r , k é uma constante e α é geralmente próximo de 1.

Figura 3. Relação inversa entre a frequência de uma palavra e sua posição no ranking, onde poucas palavras são muito frequentes e a maioria ocorre raramente, seguindo uma distribuição do tipo potência.



Intervalo de 15 minutos

Aplicando as Leis na Análise da Produção Científica na Prática

Ambiente de Trabalho Prático

- ▶ **Python:** linguagem de programação de alto nível, versátil e amplamente utilizada em ciência de dados, machine learning e automação, com sintaxe clara e grande ecossistema de bibliotecas.
- ▶ **Dataset:** conjunto estruturado de dados, normalmente organizado em linhas (registros) e colunas (variáveis), podendo vir em formatos como CSV, Excel, JSON ou SQL.
- ▶ **pandas:** biblioteca do Python para manipulação eficiente de dados tabulares, oferecendo estruturas como *DataFrame* e *Series* para importar, limpar, transformar e analisar datasets.
- ▶ **matplotlib.pyplot:** módulo da biblioteca Matplotlib para criação de gráficos (linhas, barras, histogramas e dispersão).
- ▶ **Google Colab:** ambiente online gratuito fornecido pelo Google que permite executar códigos Python na nuvem, facilitando experimentos, compartilhamento e análise de dados.

- ▶ Acesse o [Google Colab](#), faça o login com sua conta Google.
- ▶ Abra o Google Classroom da disciplina, selecione a guia Atividades → Aulas → Aula 02.
- ▶ Por fim, clique no arquivo “bibliometria_aula_02.ipynb” e selecione para “Abrir com o Google Colaboratory” (Google Colab).

ATIVIDADE PRÁTICA

Objetivo: Aplicar as Leis de Bradford, Lotka e Zipf em um “dataset” de produção científica.

Passos:

1. Carregar o “dataset” no Google Colab usando pandas.
2. Aplicar a Lei de Bradford para identificar os periódicos mais produtivos.
3. Aplicar a Lei de Lotka para analisar a produtividade dos autores.
4. Aplicar a Lei de Zipf para examinar a frequência das palavras nos títulos dos artigos.
5. Visualizar os resultados com gráficos usando matplotlib.pyplot.
6. Gere um conjunto maior de dados e verifique se as leis continuam válidas.

Duração: 45 minutos.

- ▶ **Leitura 1:** As Leis da Bibliometria em Diferentes Bases de Dados Científicos
<http://dx.doi.org/10.5007/2175-8077.2016v18n44p111>
- ▶ **Leitura 2:** How to design bibliometric research: an overview and a framework proposal
<https://doi.org/10.1007/s11846-024-00738-0>
- ▶ **Leitura 3:** A relational database for bibliometric analysis
<https://doi.org/10.1016/j.joi.2010.06.007>

Nessa aula estudamos os principais conceitos relacionados à Gestão de Dados Científicos (GDC) e as Leis de Bradford, Lotka e Zipf. Abordamos:

- ▶ Gestão de Dados Científicos: importância, ciclo de vida e princípios FAIR.
- ▶ Relação entre GDC e Ciência Aberta.
- ▶ O caos da informação e a necessidade de leis matemáticas.
- ▶ As Três Grandes Leis: Lotka, Bradford e Zipf.
- ▶ Fundamentos da comunicação científica e indicadores bibliométricos.
- ▶ Aplicações práticas usando Python e Google Colab.

As Leis da Produção Científica: Organizando o Caos da Informação




Lei de Lotka:

Poucos pesquisadores de elite produzem a maioria dos artigos científicos em uma área.



Lei de Bradford:


Um pequeno núcleo de periódicos concentra a maior parte dos artigos relevantes sobre um tema.



Lei de Zipf:

A frequência das palavras é inversamente proporcional à sua frequência, enquanto a maioria é rara.

Em qualquer texto, poucas palavras são usadas com muita frequência, enquanto a maioria é rara.



- ALVARADO, R. U. **A Lei de Lotka na bibliometria brasileira**. *Ciência da Informação*, SciELO Brasil, v. 31, p. 14–20, 2002. doi:[10.1590/S0100-19652002000200002](https://doi.org/10.1590/S0100-19652002000200002).
- BORTOLOSSI, H. J.; QUEIROZ, J. J. D. B.; SILVA, M. M. da. **A Lei de Zipf e Outras Leis de Potência em Dados Empíricos**. 2011.
- BROOKES, B. "Sources of information on specific subjects by sc bradford. *Journal of information science*, Sage Publications Sage CA: Thousand Oaks, CA, v. 10, n. 4, p. 173–175, 1985. doi:[10.1177/016555158501000406](https://doi.org/10.1177/016555158501000406).
- NARANAN, S. **Bradford's law of bibliography of science: an interpretation**. *Nature*, Nature Publishing Group UK London, v. 227, n. 5258, p. 631–632, 1970. doi:[10.1038/227631a0](https://doi.org/10.1038/227631a0).
- PINHEIRO, L. V. R. **Lei de Bradford: uma reformulação conceitual**. Ibict, 1983.
- PINHEIRO, R. G.; ALMEIDA, B. d. **As estratégias de internacionalização: um estudo bibliométrico aplicando as leis de Lotka, Bradford e Zipf na base SPELL no período de 2008 A 2018**. *Revista de Administração, Contabilidade e Economia da Fundace, Ribeirão Preto*, v. 11, n. 1, p. 60–79, 2020. doi:[10.13059/RACEF.V11I1.656](https://doi.org/10.13059/RACEF.V11I1.656).