

Inteligência Artificial Generativa Aplicada na Análise da Produção Científica

Aula 04/12

Prof. Dr. Edson Melo de Souza

Programa de Pós-Graduação em Informática e Gestão do Conhecimento (PPGI)
Programa de Pós-Graduação em Gestão de Projetos (PPGP)
Universidade Nove de Julho

22 de abril de 2026

Limpeza e Normalização de Metadados em Bibliometria

- ▶ Capacitar alunos a identificar inconsistências em metadados bibliográficos e aplicar técnicas de normalização para garantir indicadores bibliométricos confiáveis.
- ▶ Explorar ferramentas e metodologias para limpeza de dados, abordando desafios comuns na análise bibliométrica.
- ▶ Dominar técnicas de tratamento e padronização de dados bibliográficos para garantir qualidade e replicabilidade.


O Impacto do “Lixo” nos Dados

Contextualização


A bibliometria não conta apenas documentos; ela mapeia relacionamentos. Se o “nó” do relacionamento (autor ou instituição) estiver duplicado com nomes diferentes, a rede se quebra (PRITCHARD, 1969).

- ▶ Estudo de Caso: Imagine calcular o Índice-H do pesquisador “José Silva”, mas seus artigos estão listados sob “J. Silva”, “Jose Silva” e “J. S. da Silva”. O resultado? Um Índice-H subestimado.
- ▶ Outro Exemplo: Uma instituição chamada “Universidade Federal do Rio de Janeiro”, mas também aparece como “UFRJ” e “Federal University of Rio de Janeiro”. Isso pode levar a uma análise incorreta da produção científica da instituição.

Consequência: Em vez de um autor com 100 citações, temos 4 autores com 25 citações cada. O índice H cai drasticamente, prejudicando financiamentos e rankings.



ESTUDO DE CASO: JOSÉ SILVA



CONSEQUÊNCIA: ÍNDICE-H **CAI** DRASTICAMENTE. PREJUDICA FINANCIAMENTOS E RANKINGS.

Pró

1. In

2. In
tr

3. Tr
ch

4. Em
(pr
er

Discussão

Por que a Limpeza de Dados é Crucial em Bibliometria?

- ▶ **Precisão dos Indicadores:** Dados inconsistentes podem levar a métricas imprecisas, afetando avaliações de impacto e produtividade.
- ▶ **Credibilidade da Pesquisa:** Análises baseadas em dados sujos podem comprometer a confiança nos resultados.
- ▶ **Tomada de Decisão Informada:** Instituições e pesquisadores dependem de dados limpos para decisões estratégicas.
- ▶ **Eficiência na Análise:** Dados bem estruturados facilitam análises mais rápidas e eficazes.


LIMPEZA

(Remover sujeira)



NORMALIZAÇÃO

(Padronizar variantes)



Diagnósticos de Problemas Comuns

1. **Afiliações Institucionais Divergentes:** Diferentes formas de nomear a mesma instituição. **Exemplo:** “Univ Sao Paulo”, “USP”, “Universidade de São Paulo”, “University of Sao Paulo”, “Luiz de Queiroz College of Agriculture”. **Desafio:** Separar “Departamento” de “Instituição” em registros bibliográficos.

2. **Ambiguidade e Dispersão de Autores:** Ausência de informações cruciais como ano de publicação ou título. **Homônimos:** Wang, Y. (Existem milhares na China). Como saber se é o mesmo? **Variação de Nome:** García-Márquez, G. vs Márquez, G. G.


3. **Títulos de Periódicos e Conferências:** Registros repetidos que distorcem análises quantitativas. **Abreviações vs. Títulos completos:** (*J. Am. Chem. Soc.* vs *Journal of the American Chemical Society*).

4. **Dados Duplicados:** Mesmos registros inseridos várias vezes. **Exemplo:** Um artigo listado múltiplas vezes em bases diferentes.

Intervalo de 15 Minutos

- ▶ **Excel:** Planilha eletrônica amplamente utilizada para manipulação básica e limpeza de dados.
- ▶ **OpenRefine:** Ferramenta poderosa para limpeza e transformação de dados. Permite identificar e corrigir inconsistências em grandes conjuntos de dados bibliográficos ([OpenRefine Development Team, 2023](#)).
- ▶ **Python com Pandas:** Biblioteca versátil para manipulação de dados. Scripts personalizados podem ser criados para automatizar a limpeza e normalização de metadados.
- ▶ **R com Bibliometrix:** Pacote específico para análise bibliométrica, que inclui funções para limpeza e padronização de dados ([ARIA; CUCCURULLO, 2017](#)).


Guia Visual: Higienização de Dados Bibliométricos



DADOS BRUTOS & INCONSISTENTES


Elimine Registros Duplicados

Use o DOI ou a combinação de Título, Ano e Autor para identificação.



Padronize Nomes e Instituições

Agrupe variações como "E. M. Souza" e "Souza, Edson M." em uma identidade única.



Corrija Erros de Digitação

Assegure a consistência de termos e títulos, corrigindo a formatação.



Prepare para a Análise

Exporte os dados limpos para um arquivo CSV compatível com o software de análise.



Princípios Essenciais



Mantenha Sempre o Original

Antes de iniciar, faça uma cópia de segurança dos dados brutos.



Documente Todas as Alterações

Garanta transparência e a possibilidade de replicar o processo de limpeza.



Automatize Tarefas Repetitivas

Considere o uso de scripts para otimizar a limpeza e reduzir erros.



Verifique os Resultados Finais

Após a limpeza, confira se os dados estão corretos e consistentes.

Exercício Prático de Limpeza de Dados com Excel

Utilizando o “dataset” fornecido no Google Classroom na guia (Aividades → Aulas → Aula 04 → dados.csv) contendo metadados bibliográficos, vamos aplicar técnicas de limpeza e normalização para corrigir inconsistências e preparar os dados para análise bibliométrica. O que vamos fazer:

- ▶ Importar os dados para o Google Planilhas ou Excel.
- ▶ Identificar e remover duplicatas (usando DOI ou combinação Title + Year + Authors).
- ▶ Padronizar nomes de autores e instituições (“E. M. Souza”, “Souza, Edson M.”, “Edson Melo de Souza” → uma única identidade). Converter para “Universidade Nove de Julho (UNINOVE)”
- ▶ Corrigir erros de digitação e formatação (“Bibliometric Analsys” → “Bibliometric Analysis”).
- ▶ Criar um CSV para usar no VOSviewer.

- ▶ **OpenRefine:** Importar os dados limpos do Excel para o OpenRefine para uma análise mais aprofundada. Utilizar suas funcionalidades para identificar padrões e inconsistências adicionais.
- ▶ **VOSviewer:** Exportar os dados finalizados para o VOSviewer para visualização e análise bibliométrica. Criar mapas de coautoria, coocorrência de termos e outras redes relevantes (ECK; WALTMAN, 2010).

- ▶ Adote padrões consistentes ao inserir novos dados bibliográficos.
- ▶ Utilize identificadores únicos, como ORCID para autores e ROR para instituições.
- ▶ Realize verificações regulares de qualidade dos dados para identificar e corrigir problemas rapidamente.
- ▶ Mantenha-se atualizado com as melhores práticas em gestão de dados bibliográficos.

Garantindo a Qualidade dos Dados Bibliográficos

Para assegurar a integridade e a usabilidade de informações acadêmicas, é fundamental seguir um conjunto de boas práticas. Estas diretrizes formam um ciclo contínuo de gestão para manter a excelência dos dados bibliográficos.



1. Padronize a Inserção de Dados

Adote padrões consistentes ao inserir novas informações bibliográficas.



2. Use Identificadores Únicos

Utilize ORCID para autores e ROR para instituições para evitar ambiguidades.



4. Mantenha-se Atualizado

Acompanhe as melhores e mais recentes práticas em gestão de dados.

3. Verifique Regularmente

Realize auditorias de qualidade para identificar e corrigir problemas rapidamente.



- ▶ [] **Remoção de duplicatas:** O mesmo artigo aparece duas vezes (ex: pré-print e publicado)?
- ▶ [] **Padronização de Afiliações:** Todas as variantes da instituição alvo foram mapeadas para o nome oficial?
- ▶ [] **Disambiguação de Autores:** Verifiquei se “Silva, J.” é o mesmo autor em todos os registros usando a afiliação ou área temática como dica?
- ▶ [] **Ano de Publicação:** Existem datas impossíveis (ex: 2029) ou vazias?
- ▶ [] **Tipo de Documento:** Estou misturando Artigos com Editoriais ou Correções? (Geralmente devem ser analisados separadamente).

Exercício de Fixação

Cenário: Você recebeu uma lista de publicações para avaliar a colaboração internacional da “Universidade Federal do Rio de Janeiro”.

Problema: Ao fazer a nuvem de palavras, aparecem:

- ▶ UFRJ
- ▶ Univ. Fed. Rio de Janeiro
- ▶ Federal University of Rio de Janeiro
- ▶ COPPE - UFRJ


Tarefa: Utilizando o OpenRefine ou Excel, crie uma tabela “De → Para” unificando todas as variantes sob a sigla “UFRJ”.

- ▶ **Leitura 1:** bibliometrix: An R-tool for comprehensive science mapping analysis
<https://doi.org/10.1016/j.joi.2017.08.007>
- ▶ **Leitura 2:** Software survey: VOSviewer, a computer program for bibliometric mapping
<https://doi.org/10.1007/s11192-009-0146-3>
- ▶ **Leitura 3:** Statistical bibliography or bibliometrics?
<https://doi.org/10.1108/eb026468>


- ▶ **Motivação e impacto na bibliometria:** A bibliometria depende de relacionamentos entre nós (autores e instituições) e que variantes de nomes fragmentam redes e distorcem indicadores, como o Índice-H, ao dividir citações entre identidades duplicadas (exemplo do pesquisador e da instituição com múltiplas grafias).
- ▶ **Principais problemas de qualidade em metadados:** São diagnosticadas quatro classes recorrentes de erro em bases bibliográficas: afiliações institucionais divergentes, ambiguidade e dispersão de autores, inconsistências em títulos de periódicos e conferências (abreviações versus nomes completos) e duplicidade de registros em múltiplas fontes.
- ▶ **Fluxo de limpeza, ferramentas e prevenção:** Fluxo prático com remoção de duplicatas (por DOI ou Title+Year+Authors), padronização de autores e instituições, correção de erros de digitação e exportação para análise em VOSviewer, com suporte de Excel, OpenRefine, Python/Pandas e R/Bibliometrix.

O Lixo nos Dados: A Importância da Limpeza de Metadados na Bibliometria

O PROBLEMA: Dados "Sujos" Distorcem a Realidade Científica



A SOLUÇÃO: Diagnóstico, Limpeza e Prevenção



- ARIA, M.; CUCCURULLO, C. **Bibliometrix: An R-tool for comprehensive science mapping analysis**. *Journal of Informetrics*, v. 11, n. 4, p. 959–975, 2017.
- ECK, N. J. V.; WALTMAN, L. **Software survey: VOSviewer, a computer program for bibliometric mapping**. *Scientometrics*, v. 84, n. 2, p. 523–538, 2010.
- OpenRefine Development Team. **OpenRefine: A free, open-source tool for cleaning messy data**. 2023. Software. Disponível em: <https://openrefine.org>.
- PRITCHARD, A. **Statistical bibliography or bibliometrics?** [S.l.]: Journal of Documentation, 1969. v. 25. 348–349 p.