

Inteligência Artificial Generativa Aplicada na Análise da Produção Científica

Aula 10/12

Prof. Dr. Edson Melo de Souza

Programa de Pós-Graduação em Informática e Gestão do Conhecimento (PPGI)
Programa de Pós-Graduação em Gestão de Projetos (PPGP)
Universidade Nove de Julho

3 de junho de 2026

Análise de Tendências e Topic Modeling com Inteligência Artificial

- ▶ Compreender os fundamentos da Modelagem de Tópicos (LDA) aplicada a grandes volumes de metadados científicos.
- ▶ Implementar um pipeline prático em Python utilizando Scikit-Learn para extração de clusters temáticos.
- ▶ Interpretar padrões emergentes e sinais fracos (Weak Signals) através da integração entre modelos estatísticos e IA Generativa.

O Futuro da Análise de Dados: O Nascimento da Inteligência Científica

A convergência entre campos tecnológicos e métricas acadêmicas que resultam no conceito de Inteligência Científica, detalhando os três pilares tecnológicos que se sobrepõem no cenário moderno de pesquisa.



Bibliometria Tradicional

O pilar focado em métricas de publicações, citações e impacto acadêmico estabelecido.



Machine Learning

O uso de algoritmos avançados para identificar padrões complexos em grandes volumes de dados.



IA Generativa


Novas capacidades de criação, síntese e processamento de linguagem natural no campo científico.

O Ecossistema da Modelagem de Tópicos

Diferente da busca por palavras-chave, aqui buscamos a semântica oculta nos textos ([VAYANSKY; KUMAR, 2020](#)).

- ▶ **Conceito de LDA (Latent Dirichlet Allocation):** Como a matemática agrupa palavras que “andam juntas” ([JELODAR et al., 2019](#)).
- ▶ **Documentos vs. Tópicos:** A ideia de que um artigo não fala de uma coisa só, mas de uma mistura de temas.
- ▶ **Pré-processamento Crítico:** Limpeza de ruídos, remoção de “stop-words” acadêmicas e padronização de termos.

O Fluxo da Modelagem de Tópicos: Da Palavra ao Significado



Foco na implementação do código e nos ajustes necessários para o rigor científico.

- ▶ **Vetorização:** Transformando palavras em números (CountVectorizer e TF-IDF) ([KRAMER, 2016](#)).
- ▶ **O parâmetro K:** Como decidir o número ideal de tópicos para não fragmentar demais a análise.
- ▶ **Visualização Interativa:** Uso de mapas de distância para entender se os temas estão muito próximos ou bem definidos.

Desvendando a Modelagem de Tópicos com LDA

Do Código à Lógica



Latent Dirichlet Allocation (LDA)

Algoritmo matemático que agrupa palavras que costumam aparecer juntas nos textos.



Pré-processamento Crítico

Limpeza de ruídos e remoção de "stop-words" para padronizar os termos analisados.



```
# Excepto de Código Python: Treinamento do Modelo LDA
import gensim
from gensim.utils import simple_preprocess
from gensim.parsing.preprocessing import STOPWORDS
from gensim.corpora import Dictionary

# 1. Corregor e Pré-processar Dados
raw_text = "Grande volume de textos não estruturados para análise..."
processed_text = [word for word in simple_preprocess(raw_text) if word not in STOPWORDS]
texts = [processed_text]

# 2. Criar Dicionário e Corpus
id2word = Dictionary(texts)
corpus = [id2word.doc2bow(text) for text in texts]

# 3. Treinar Modelo LDA
lda_model = gensim.models.LdaMulticore(corpus=corpus, id2word=id2word, num_topics=5)

# 4. Exibir Tópicos
print(lda_model.print_topics())
```

Implementação simplificada para carregar dados e treinar o modelo de tópicos.

Da Análise à Visualização



Documentos vs. Tópicos

A ideia de que um artigo é uma mistura de múltiplos temas, não um assunto único.



Semântica Oculta

A transição da busca por palavras-chave para a descoberta de contextos profundos.




Gráfico de Bolhas de Tópicos

Representação visual da relevância e da distância semântica entre os temas gerados.

NotebookLM

Roteiro para Aquisição de Dados Bibliométricos

- ▶ **Fontes de Dados:** Scopus.
- ▶ **Construção da Query:** `TITLE-ABS-KEY(("artificial intelligence" OR "machine learning") AND "healthcare") AND PUBYEAR > 2018 AND ( LIMIT-TO ( OA,"all" ) ) AND ( LIMIT-TO ( DOCTYPE,"ar" ) ) AND ( LIMIT-TO ( LANGUAGE,"English" ) )`.
- ▶ **Exportação CSV:** Incluir os campos "Author(s)", "Document title", "Year", "Abstract" e "Author keywords".
- ▶ **Limpeza e Preparação:** Remover duplicatas, normalizar texto (lowercase, remoção de pontuação) e filtrar por idioma.

 Documents 1 – 16203

What information do you want to export?

 Citation information☐ Bibliographical information Abstract & keywords☐ Funding details☐ Other information☒ Author(s)☐ Affiliations☒ Abstract☐ Number☐ Tradenames & manufacturers☒ Document title☐ Serial identifiers (e.g. ISSN)☒ Author keywords☐ Acronym☐ Accession numbers & chemicals☒ Year☐ PubMed ID☐ Indexed keywords☐ Sponsor☐ Conference information☐ EID☐ Publisher☐ Funding text☐ Include references☐ Source title☐ Editor(s)☐ Volume, issues, pages☐ Language of original document☐ Citation count☐ Correspondence address☐ Source & document type☐ Abbreviated source title☐ Publication stage☐ DOI☐ Open access[Select all information](#)☒ Truncate to optimize for Excel ☐ Save as preference[Export](#)

Ambiente de Desenvolvimento, Configuração e Exemplo

- ▶ **Google Colab:** Ideal para experimentação e visualização passo a passo.
- ▶ **Bibliotecas Necessárias:** pandas, scikit-learn, matplotlib, pyLDAvis.
- ▶ **Configurações de LDA:** Número de tópicos (K), número de iterações, e parâmetros de regularização.
- ▶ **Validação dos Resultados:** Coerência dos tópicos e interpretação qualitativa dos clusters formados.

O arquivo de exemplo para o exercício prático está disponível no Google Classroom da disciplina em Atividades → Aulas → Aula 10 → bibliometria_aula10.ipynb, assim como os dados: “dados_lda.csv”.

Como antecipar o que será relevante antes que se torne senso comum.

- ▶ **Sinais Fracos (Weak Signals):** Identificação de temas emergentes que ainda não ganharam tração.
- ▶ **Análise Temporal:** Como os tópicos evoluem ao longo do tempo e o que isso indica sobre futuras direções de pesquisa.
- ▶ **Integração com IA Generativa:** Utilização de modelos como GPT para interpretar e expandir os insights obtidos pela LDA, criando narrativas sobre o futuro da pesquisa.

IA Generativa na Interpretação de Padrões

A combinação de análise quantitativa com interpretação qualitativa ([TRINDADE; OLIVEIRA, 2024](#)).

- ▶ **Geração de Resumos Temáticos:** Usar IA para criar resumos compreensíveis dos clusters de tópicos.
- ▶ **Exploração de Cenários Futuros:** Simular como os temas identificados podem se desenvolver nos próximos anos.
- ▶ **Validação Humana:** A importância do olhar crítico do pesquisador para validar as interpretações geradas pela IA.


O prompt para a interpretação de padrões está disponível no Google Classroom da disciplina em Atividades → Aulas → Aula 10 → `prompt.txt`.

Conclusão focada na entrega de valor para instituições e pesquisadores.

- ▶ **Identificação de Gaps:** Onde estão as oportunidades de pesquisa ainda não exploradas?
- ▶ **Análise de Competitividade:** Comparar o perfil temático da sua instituição com a média mundial.
- ▶ **Direcionamento de Fomento:** Apoiar agências de fomento na escolha de áreas estratégicas para investimento.

Inteligência Científica: O Futuro da Análise de Produção Acadêmica

O Pipeline da Modelagem de Tópicos & Aplicações Estratégicas



Aplicações e Impacto Estratégico

Visualização de Tópicos & Status de Temperatura



Status de Temperatura

Status	Descrição do Tópico	Relevância Global
Quente	Inovação, Tecnologia, IA	Alta
Estável	Metodologia, Estudo, Análise	Média
Frio	Legislação, Antigo, Arquivo	Baixa

- ▶ **Modelagem de Tópicos para análise de tendências:** Alternativa à busca por palavras-chave, tratando documentos como misturas de temas e buscando a semântica latente em grandes volumes de metadados científicos.
- ▶ **Pipeline prático e rigor metodológico em Python:** Fluxo de trabalho com Scikit-learn, incluindo vetorização (CountVectorizer e TF-IDF), escolha do número de tópicos (K) e visualização para inspecionar separação e proximidade temática.
- ▶ **Sinais fracos, interpretação com IA generativa e uso estratégico:** Detecção de *weak signals* e análise temporal da evolução dos tópicos, integrando IA generativa para produzir resumos temáticos, explorar cenários futuros e apoiar tomada de decisão, com validação humana como etapa obrigatória.

Dashboard de Inteligência: O Ecossistema da Modelagem de Tópicos

Fundamentos da Modelagem Semântica

Latent Dirichlet Allocation (LDA)



Algoritmo matemático que agrupa palavras que costumam aparecer juntas nos textos.

Documentos como Misturas de Temas



Um único artigo não é monotemático, mas uma composição de múltiplos tópicos simultâneos.

Semântica vs. Palavras-Chave



Palavras-Chave

O foco é o significado oculto, indo além da simples busca por termos isolados.



Semântica

Do Pré-processamento ao Monitoramento

Refino e Limpeza Crítica



Remoção de ruídos e "stop-words" acadêmicas para garantir a pureza dos tópicos.

Status de Temperatura de Tópicos

Classificação da relevância atual dos temas entre Quente, Estável ou Frio.



Quente

Tópico: Inovação, Tecnologia, IA |
Relevância Global: Alta



Estável

Tópico: Metodologia, Estudo, Análise |
Relevância Global: Média



Frio

Tópico: Legislação, Antigo, Arquivo |
Relevância Global: Baixa

- JELODAR, H. *et al.* **Latent Dirichlet allocation (LDA) and topic modeling: models, applications, a survey.** *Multimedia tools and applications*, Springer, v. 78, n. 11, p. 15169–15211, 2019.
- KRAMER, O. **Scikit-learn**. In: *Machine learning for evolution strategies*. [S.l.]: Springer, 2016. p. 45–53.
- TRINDADE, A. S. C. E. d.; OLIVEIRA, H. P. C. d. **Inteligência Artificial (IA) Generativa e Competência em Informação: habilidades informacionais necessárias ao uso de ferramentas de ia generativa em demandas informacionais de natureza acadêmica-científica.** *Perspectivas em Ciência da Informação*, SciELO Brasil, v. 29, p. e–47485, 2024.
- VAYANSKY, I.; KUMAR, S. A. **A review of topic modeling methods.** *Information Systems*, Elsevier, v. 94, p. 101582, 2020.